


Motivation

之前大部分研究方向都基于 FCN 范式的 Decoder - Encoder 结构，也就是先把一个图像 downscale 来提取出高维度的信息，然后再 upscaling 补充细节信息。但是这样有几个问题：

- 实际感受野远小于理论感受野
- 下采样太多会导致小目标细节信息丢失
- 参数量增大

之前的想法有用改造卷积（比如 PSPnet, deeplab 等）也有用 attention 机制的，但是换汤不换药。ViT 的出现给作者带来了新的想法：

Method



encoder 部分，按照 16×16 的小块划分，然后给每个位置学习一个特定的嵌入 p_i ，在用 一个线性投影函数(patch embeddings) e_i 形成最终的一维序列 $E = \{e_i + p_i\}$ ，学习了对应的位置信息。这边我们需要注意他的patch embedding和position embedding，这部分实际上是和 ViT 完全一样的，所以允许我们直接套用之前的权重。这也带来一个问题：我们知道 Transformer 是没有多层次感受能力的，不像 CNN，CNN 是可以有多个层级的感受特征的。所以需要后面的 decoder 来分层次合并特征。

Decoder 部分：作者给了三种结构：

- 1 第一种是 conv + BN + ReLU + conv，然后双线性上采样回原图分辨率。
- 2 第二种是渐进式上采样，参考图 (b)，也就是每次上采样 2 倍，参考 U-net 的 Decoder
- 3 第三种是类似金字塔的融合结构，每隔 6 层抽取一个输出特征，然后 reshape 成 $\frac{1}{16}$ 的尺寸，经过一个 3 层的网络+4 倍双线性上采样操作，最后自顶向下逐层融合，按照通道维度进行拼接，然后直接 4 倍双线性上采样回去。这边是因为他要多个层次的信息。

Experiments

数据集： Cityscapes, ADE20k, PASCAL Context

类似 PSPnet，作者同样引入了辅助损失，研究了一下，辅助损失这个东西其实就是为了改善深层次网络中梯度消失的问题，并且提供中间的监督，让网络变得更加清晰和结构化。

作者直接把 ViT 训练出来的权重用于 SETR 的编码器进行权重初始化。